

ICS 33.030
CSS M21

YD

中华人民共和国通信行业协会标准

YD/T XXXXX—XXXX

面向互联网的医疗人工智能辅助决策 基于 病理图像的辅助决策系统算法指标和测试 方法

Internet-oriented pathological image-based decision-making system performance indicators and test methods

(报批稿)

XXXX - XX - XX 发布

XXXX - XX - XX 实施

中华人民共和国工业和信息化部 发布

目 次

前 言II

引 言III

1 范围.....1

2 规范性引用文件.....1

3 术语与定义.....1

4 缩略语.....4

5 性能指标及计算方法.....4

 5.1 临床性能指标.....4

 5.2 其他性能指标.....8

6 测试方法.....8

 6.1 测试前准备.....8

 6.2 测试流程.....10

 6.3 测试后封样.....12

参考文献.....13

附 录 A (资料性).....14

前 言

本文件按照GB/T 1.1—2020《标准化工作导则 第1部分：标准化文件的结构和起草规则》的规定起草。

请注意本文件中的某些内容可能涉及专利。本文件的发布机构不承担识别专利的责任。

本文件由中国通信标准化协会提出和归口。

本文件起草单位：中国信息通信研究院、深圳市腾讯计算机系统有限公司、中国电信集团有限公司、工业互联网创新中心(上海)有限公司、中国人民解放军总医院、首都医科大学附属北京积水潭医院、北京积水潭骨科机器人工程研究中心有限公司。

本文件主要起草人：滕依杉、李静雯、何昆仑、王军强、赵阳光、李曼、闵栋、王倩怡、伍健荣、方金武、王道洋、李慧、庄严、蒋协远、韩巍、公茂琪、张腾、谭杰、李金奇、贾翌、周学林、张维军、任海英。

引 言

随着计算机技术的发展和人工智能技术的成熟,面向互联网的医疗人工智能辅助决策系统蓬勃发展,其具有阅片耗时短,检出效率高等优点,可以有效缓解病理科医生的工作压力并且提高检出率和准确率。辅助决策系统在临床活动中会辅助医务人员进行临床决策,因此存在很大的临床使用风险,漏诊和误诊可能会导致疾病延误和过度医疗。对其进行全面系统的安全性和有效性测试非常必要。建立面向互联网的医疗人工智能辅助决策系统的算法指标和测试方法系列标准,能够进一步规范辅助决策系统的技术标准,为监管机构提供有力的监管依据。

使用病理切片或细胞涂片直接观察组织细胞、判断肿瘤性质,其结果常被视为最终诊断,基于病理图像的辅助决策系统是癌症早期检出的重要手段,但是目前并无相关性能指标和测试方法的标准,建立面向互联网基于病理图像的辅助决策系统性能指标和测试方法的标准体系,能够推动该类产品的持续健康发展。

面向互联网的医疗人工智能辅助决策 基于病理图像的 辅助决策系统算法指标和测试方法

1 范围

本文规定了面向互联网的医疗人工智能辅助决策基于病理图像的辅助决策系统算法指标和测试方法，包括性能指标及计算方法、测试流程等内容。

本文件适用于面向互联网的基于病理图像的医疗人工智能辅助决策系统。

2 规范性引用文件

下列文件中的内容通过文中的规范性引用而构成本文件必不可少的条款。其中，注日期的引用文件，仅该日期对应的版本适用于本文件；不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

T/CCSA 351-2022 面向互联网的医疗人工智能辅助决策基于眼底彩照的青光眼辅助筛查系统技术要求

3 术语与定义

下列术语和定义适用于本文件。

3.1 统计学

3.1.1

样本 sample

一个或多个抽样单元组成的总体的子集

[来源：GB/T 3358.1-2009，1.3]

3.1.2

标准正态分布 standard normal distribution

具有如下概率密度函数的分布

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \quad (1)$$

其中， $-\infty < x < +\infty$

[来源：GB/T 3358.1-2009，2.51]

3.2 人工智能

3.2.1

二分类 binary classification

将对象归入两种类别之一的判断任务或功能。

3.2.2

多分类 multiple classification

将对象归入多种类别之一的判断任务或功能。

3.2.3**混淆矩阵 confusion matrix**

混淆矩阵也称误差矩阵，是用于分类精度评价的一种标准格式，用n行n列的矩阵形式来表示。

3.2.4**真阳性 true positive**

样本的真实类别是阳性，且模型预测的结果也是阳性。

3.2.5**真阴性 true negative**

样本的真实类别是阴性，且模型将其预测成为阴性。

3.2.6**假阳性 false positive**

样本的真实类别是阴性，但是模型将其预测成为阳性。

3.2.7**假阴性 false negative**

样本的真实类别是阳性，但是模型将其预测成为阴性。

3.2.8**准确度 accuracy**

被正确分类的样本比例。

3.2.9**敏感度 sensitivity**

又称召回率，是指实际为阳性的样本中，判断为阳性的比例。

3.2.10**特异度 specificity**

又称真阴率，是指实际为阴性的样本中，判断为阴性的比例。

3.2.11**精确度 precision**

描述在所有判别为阳性的结果中，真正阳性所占的比例。

3.2.12**F-score**

F-score是一种统计量，F-score又称为F-measure，是信息检索领域常用的一个评价标准，常用于评价分类模型的好坏。

3.2.13**Kappa系数**

Kappa系数是一个用于一致性检验的指标，在人工智能领域用来衡量分类精度，可以基于混淆矩阵计算得到。

3.2.14**ROC曲线 receiver operating characteristic curve**

ROC曲线是通过变动诊断阈值展示二分类系统的诊断能力的图线工具，基于敏感度和特异度绘制得到。

3.2.15**AUC值 area under curve**

AUC值被定义为ROC曲线下与坐标轴围成的面积。

3.2.16

目标检测 object detection

目标检测是指找出图像中所有感兴趣的目标，确定它们的位置和大小。

3.2.17

交并比 intersection over union

交并比是目标检测中的一种评估指标，用来量化金标准区域与算法预测得到的候选区域的重叠范围。

3.2.18

Dice系数

Dice系数主要是用来计算算法预测候选区域与金标准区域的相似性的，最理想的情况是完全相似，即比值为1。

3.2.19

真阳率 true positive rate

是指所有病灶中，被正确检出的比例。

3.2.20

平均假阳性个数 false positive number

是指平均每一例影像中包含的非病灶位置误定位的个数。

3.2.21

FROC曲线 free response receiver operating characteristic curve

FROC曲线全称为不受限接受者操作特征曲线。经典的ROC曲线不能解决对一例图像上多个病灶进行评价的问题，而FROC曲线允许对每幅图像上的任意病灶进行评价。

3.2.22

鲁棒性 robustness

人工智能系统在任何情况下保持其性能水平的能力。

[来源：ISO/IEC 24029-1, 3.6]

3.2.23

泛化性 generalization

泛化性是指算法对未知数据的预测能力。算法训练的目的是学到隐含在数据背后的规律，对具有同一规律的训练集以外的数据，经过训练的算法也能给出合适的输出，即认为该算法泛化性能良好。

3.2.24

可再现性\可重复性 repeatability

在算法测试环境和初始条件相同的情况下，算法对于相同的数据集的不同测试结果之间的一致性即为算法的可再现性/可重复性。该性能指标的评估场景为软件更新或算法更新后的性能测试。

3.2.25

豪斯多夫距离 hausdorff distance

豪斯多夫距离又称豪氏距离，用于分割预测结果和专家标定之间的形状相似性评价，豪氏距离用于评价两个区域之间最大不匹配的程度，如果模型的预测输出与专家所做的标记是完全一致的，则两者间的豪氏距离为0。

3.3 医学

3.3.1

病理切片 pathological section

病理切片是指取一定大小的病变组织，用病理组织学方法染色制成切片，组织结构对不同染料的结合程度不同，由此显示组织切片和细胞标本中的成分以及病变的一般形态结构特征从而能够鉴别、诊断和治疗恶性肿瘤。

3.3.2

金标准 gold standard

金标准由临床医师根据原始数据精确标注切片图像进行得到，为确保标注过程一致性和准确性，每条数据标注以小组方式进行，每小组应由3人组成，相互独立标注，结果达到多数一致直接入库，完全不一致时组内讨论，讨论达成一致入库，无法一致剔除。

3.3.3

细胞核 nucleus

细胞核以染色质形式贮存了绝大部分遗传信息，通常肿瘤细胞的核明显增大，细胞核的形态不规则，细胞核分裂象也相应增多。

3.3.4

浸润 invasive

浸润性指当癌细胞的生长超过了上皮的基底膜，向基底膜深层进行浸润生长。

3.3.5

非浸润 noninvasive

非浸润性指癌细胞局限在黏膜上皮层内，没有穿透基底膜，没有向基底膜的深层进行浸润，这种情况也被称为原位癌。

3.3.6

核分裂计数 mitosis Count

核分裂计数指单位面积内核分裂相的数目，通常在肿瘤核分裂最活跃的区域进行计数。

4 缩略语

下列缩略语适用于本文件。

ROI 感兴趣区域 Region of Interest

ROC 接受者操作特征 Receiver Operating Characteristic

FROC 不受限接受者操作特征 Free Receiver Operating Characteristic

IoU 交并比 Intersection over Union

TP 真阳性 True Positive

TN 真阴性 True Negative

FP 假阳性 False Positive

FN 假阴性 False Negative

5 性能指标及计算方法

5.1 临床性能指标

5.1.1 病理图像感兴趣区域（ROI）检测

5.1.1.1 场景描述

原始的病理切片图像中包含的信息并不是全部都需要的，针对病理图像染色深浅不一、细胞类型多样、细胞重叠的问题病理图像，需要从中提取感兴趣的区域，如腺体区域、上皮组织、基质区域等。

判定ROI是否具有代表性病理信息应有的相应指标，例如计算交并比大小、计算中心点距离，具体检出指标本文件中不做详细要求，系统可自行选择，但是系统应对选择的指标、计算公式与阈值要求进行说明。若金标准框与候选框满足检出指标阈值要求，则认为该处ROI定位正确，若金标准框与候选框不满足检出指标阈值要求，则认为该处ROI误定位。

5.1.1.2 性能指标

5.1.1.2.1 真阳率

计算公式：

$$\text{真阳率} = \text{正确检出的区域数} / \text{所有检出的区域数} \quad (2)$$

5.1.1.2.2 平均假阳性个数

计算公式：

$$\text{平均假阳性个数} = \text{错误检出区域数} / \text{切片图像总例数} \quad (3)$$

5.1.1.2.3 FROC 曲线

计算公式：FROC曲线的纵轴为真阳率，横轴为平均假阳性个数，根据每一个预测区域的预测概率，绘制FROC曲线，计算真阳率在平均假阳性个数分别为1/8, 1/4, 1/2, 1, 2, 4和8这7种不同情况下的平均值，作为评价指标之一。

5.1.2 病理图像分割

5.1.2.1 场景描述

分析 ROI 以捕获病理图像的相关特征，对于病理图像不同病种分析的指标不同，比如乳腺癌、肾细胞癌其特征向量主要来自病理细胞的细胞核，结肠癌、前列腺癌则主要观测其腺体，对提取的ROI分割其中的所有细胞核或腺体以便对其进行特征量化。

5.1.2.2 性能指标

在分割场景下的性能指标有三个，分别是交并比、Dice系数和豪氏距离，可根据产品实际情况进行选测。

5.1.2.2.1 交并比

计算公式：

$$IoU = |A \cap B| / |A \cup B| \quad (4)$$

其中 A 为预测范围像素的集合，B 为金标准范围像素的集合。为了观测系统在分割场景下的性能，有两种方式计算整个系统的交并比，分别是全局交并比和平均交并比。计算全局交并比时，A 为系统预测的像素集合，B 为金标准中所有像素的集合。计算平均交并比时，A 为系统预测的像素集合，B 为与预测对应的金标准像素集合，平均交并比即为交并比的平均值。实际测试时系统可自行选择两种计算方式中的一种，但是在提交检测时应进行明确。

5.1.2.2.2 Dice 系数

计算公式：

$$Dice = 2|A \cap B|/(|A| + |B|) \quad (5)$$

其中 A 为预测范围像素的集合，B 为金标准范围像素的集合。

为了观测系统在分割场景下的性能，有两种方式计算整个系统的 Dice 系数，分别是全局 Dice 系数和平均 Dice 系数。计算全局 Dice 系数时，A 为系统预测的所有像素集合，B 为金标准中所有像素的集合。计算平均 Dice 系数时，A 为系统预测的像素集合，B 为与预测对应的金标准的像素集合，平均 Dice 系数即为 Dice 系数的平均值。实际测试时系统可自行选择两种计算方式中的一种，但是在提交检测时应进行明确。

5.1.1.2.3 豪氏距离

计算公式：

$$H(A,B) = \max \left\{ \sup_{x \in G, y \in P} d(x,y), \sup_{y \in P, x \in G} d(x,y) \right\} \quad (6)$$

其中 A 为模型分割的像素点集合，B 为专家标注的像素点集合，d(x, y) 表示像素点 x 和 y 之间的欧氏距离。

5.1.3 特征量化

5.1.3.1 场景描述

特征量化指分析分割出来的病理图像的形态学特征，从而辅助诊断。不同病种分析的病理图像的形态学特征不同，比如乳腺癌主要评估细胞核的多形性、核分裂计数以及腺管形成比例，细胞核的多形性包括细胞核的大小、形状，细胞核大小参数包含核面积、核周长、最短径和最长径；核形状的参数可以参考形状因子，形状因子是反映物体形状的参数，可以反映细胞核截面形状与圆相差的程度及不规则程度，核形状越不规则，形状因子数值越大，反映细胞核形状偏离圆形越远。核分裂计数指单位面积内核分裂相的数目，通常在肿瘤核分裂最活跃的区域进行计数，核分裂计数增加常见于恶性肿瘤。腺管形成程度需要计数中央腺腔，以腺管/肿瘤区域的百分比表示。

5.1.3.2 性能指标

5.1.3.2.1 绝对误差

计算公式：绝对误差=测量值-金标准值

系统的绝对误差即为绝对误差绝对值的平均值。

5.1.3.2.2 相对误差

计算公式：相对误差=绝对误差/金标准值*100%

系统的相对误差即为相对误差绝对值的平均值。

5.1.4 病理分类分级

5.1.4.1 场景描述

病理分类分级包括良恶性分类、病理分型、风险级别等，良恶性分类指输出检出细胞结果为正常细胞和癌变细胞，分型包括浸润性病变和非浸润性病变，风险级别是针对恶性肿瘤确定其恶性的程度。

良恶性分类和分型问题为二分类问题。

风险级别分类为多分类问题。对于浸润性癌来说，分级越高，肿瘤分化越差，恶性程度越高，其预后效果越差，其风险级别分类通常可以为三分类问题，即Ⅰ级为高度分化，肿瘤细胞的分化程度接近正常细胞，恶性程度低，Ⅱ级为中度分化，Ⅲ级为低度分化，表示风险级别最高，肿瘤为高度恶性。原位癌主要根据细胞核进行分级，其风险级别分类可以进行低、中、高三分类，中、高级别原位癌比低级别预后较差，其发生浸润性癌的危险性也相对较高。

把训练样本中的某一类作为一个类，相应的将其他的两类作为一个类，这样就转化为多个二分类的问题，对于每个分类器，测试样本中出现次数最多的即为最终分类。

5.1.4.2 二分类问题性能指标

5.1.4.2.1 准确度

计算公式：

$$(TP + TN) / (TP + TN + FP + FN) \times 100\% \quad (7)$$

Commented [1]: 需要解释式中 TP TN FP FN 代表说明

5.1.4.2.2 敏感度

计算公式：

$$TP / (TP + FN) \times 100\% \quad (8)$$

Commented [滕依杉 2R2]: 在术语和缩略语中进行了说明

5.1.4.2.3 特异度

计算公式：

$$TN / (TN + FP) \times 100\% \quad (9)$$

5.1.4.2.4 精确度

计算公式：

$$TP / (TP + FP) \times 100\% \quad (10)$$

5.1.4.2.5 F-score

计算公式：

$$(1 + \beta^2) \times (\text{精确度} \times \text{敏感度}) / ((\beta^2 \times \text{精确度}) + \text{敏感度}) \quad (11)$$

其中 β 为平衡系数，一般情况下取值为1。

5.1.4.2.6 ROC曲线

绘图过程详见附录A。

5.1.4.2.7 AUC值

计算公式：假定ROC曲线是由坐标为 $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ 的点按序连接而形成，如图1所示，则AUC可估算为：

$$AUC = \frac{1}{2} \sum_{i=1}^{m-1} (x_{i+1} - x_i) \times (y_i + y_{i+1}) \quad (12)$$

5.1.4.3 多分类问题性能指标

多分类问题性能指标分为分级指标和综合指标两部分。

5.1.4.3.1 分级指标

针对每一级的分类性能评估指标包括：准确度、敏感度、特异度、精确度、F-score、ROC 曲线、AUC 值。指标说明和计算方式与上文二分类系统性能指标一致。

5.1.4.3.2 综合指标

为了综合评估多分类系统的性能，对各级计算得到的准确度、敏感度、特异度、精确度、F-score和AUC值分别进行加权平均（权重为各级样本数量），得到整个多分类系统的综合指标。

同时，Kappa系数作为衡量分类精度的指标可以比较好地反映多分类系统的综合性能，指标说明和计算公式如下：

- 说明：Kappa系数是基于混淆矩阵进行计算得到的，Kappa系数的范围为 $[-1, 1]$ ，可以认为Kappa系数越接近1，分类精度越高；Kappa系数越接近-1，分类精度越低。

- 计算公式：

$$k = \frac{P_0 - P_e}{1 - P_e} \quad (13)$$

其中 P_0 是每一类正确分类的样本数量之和除以总样本数。

假设每一类的真实样本个数分别为 $a_1, a_2, \dots, a_C$ ，而预测出来的每一类的样本个数分别为 $b_1, b_2, \dots, b_C$ ，总样本个数为 n ，则有： $P_e = \frac{a_1 \times b_1 + a_2 \times b_2 + \dots + a_C \times b_C}{n^2}$ 。

5.2 其他性能指标

其他性能指标包括鲁棒性、泛化性、可再现性\可重复性，其定义在本文件3.2.18、3.2.19、3.2.20中进行了说明。

6 测试方法

6.1 测试前准备

6.1.1 测试前准备流程

测试前准备流程如图1所示：




图1 测试前准备示意图

步骤如下：

- a) 提交检测任务；
- b) 抽取测试数据、提交检测系统；

c) 灌入封闭安全的测试环境。在正式开始测试前, 计算该待测系统的MD5值, 应与系统声称的MD5值保持一致, 确保被测试系统的唯一性。

6. 1. 2 数据集准备

6. 1. 2. 1 确定测试数据来源

单次测试数据从第三方数据库中实时抽取, 抽取的测试数据包含影像数据和数据标签。

备注：第三方数据库指符合《深度学习辅助决策医疗器械软件审评要点》中关于“用于第三方软件确认测试的第三方数据库”的专用要求, 由相应临床专业领域的权威机构（如国家临床医学研究中心）牵头创建, 满足权威性、科学性、规范性、多样性、封闭性、动态性的测评数据库。

6. 1. 2. 2 确定测试数据集样本量

测试数据集样本量根据系统预期的特异度和敏感度来确定, 可以依照如下计算公式。根据敏感度指标计算样本量公式：

$$n_1 = \frac{Z_{\frac{\alpha}{2}}^2 Psen(1 - Psen)}{d^2} \quad (14)$$

根据特异度指标计算样本量公式：

$$n_2 = \frac{Z_{\frac{\alpha}{2}}^2 Pspe(1 - Pspe)}{d^2} \quad (15)$$

其中, $Z_{\frac{\alpha}{2}}$ 为 $\frac{\alpha}{2}$ 对应的标准正态分布的上分位数, α 为0. 05, $Psen$ 为系统提供的预期敏感度, $Pspe$ 为系统提供的预期特异度, d 为置信区间宽度的一半。

二者之和是单次测试样本量的最低要求。测试样本量应在上述统计学计算方式的基础上, 以国内同类系统临床实验室病例数据为基准, 综合确定。

6. 1. 2. 3 确定测试数据集样本分布

Commented [3]: 格式不对, 正文缺少引用。全文图的编号都不对。

Commented [滕依杉 4R4]: 已修改

Commented [5]: 式中字母和单位有要求吗？

Commented [滕依杉 6R6]: 没有要求

样本分布应符合待测系统的应用场景。要求测试数据集中包含一定比例质量不佳和合并其他疾病的数据。同时要求测试数据集应有不同属性，如来源不同地区、来源不同厂商采集设备等。

6.2 测试流程

6.2.1 临床性能测试

在不同的应用场景下，临床性能测试方法有所不同，在进行该部分测试前，应先确定系统的应用场景，再进行相应测试。系统应声明其面对质量不佳数据无法处理时采取的方式。

6.2.1.1 ROI检出测试方法

在ROI检出应用场景下的测试流程示意图如图2所示：




图2 ROI检出测试流程

- (1) 在封闭安全的环境中开始测试；
- (2) 计算每个区域的检出指标，判断每个区域的诊断属性（正确检出、误定位）；
- (3) 计算系统真阳率、平均假阳性个数，并绘制FROC曲线。

6.2.1.2 图像分割测试方法

在图像分割应用场景下的测试流程示意图如图3所示：




图3 细胞核分割测试流程示意图

步骤如下：

- (1) 在封闭安全的环境中开始测试；

Commented [7]: 标题格式

Commented [滕依杉 8R8]: 已修改

(2) 根据分割得到的细胞核的边缘轮廓与原始数据标签中的边缘轮廓，计算系统的交并比和Dice系数；

6.2.1.3 特征量化测试方法

在特征量化应用场景下的测试流程示意图如图4所示：




图4 定量测量的测试流程示意图

步骤如下：

- (1) 在封闭安全的环境中开始测试；
- (2) 计算细胞核测量值的绝对误差、相对误差；
- (3) 计算系统的绝对误差、相对误差。

6.2.1.4 分类分级测试方法

在分类分级应用场景下的测试流程示意图如图5所示：




图5 分级分类测试流程示意图

步骤如下：

- (1) 在封闭安全的环境中开始测试；
- (2) 根据预测数据标签、预测概率和原始数据标签计算混淆矩阵、绘制ROC曲线；
- (3) 根据混淆矩阵和ROC曲线计算系统的临床性能指标。

6.2.2 其他性能测试

6.2.2.1 鲁棒性测试

病理图像具有独特的微观结构特征，包括组织基元部分染色、高密度分布、重叠粘连等，应抽取部分测试数据进行随机的基本变换，来进行系统鲁棒性的测试。其中基本变换包括对原图边长进行5%的裁剪、旋转（5°）、缩小（5%）、放大（5%），图片进行变换后应统一恢复至原图大小。其中进行基本变换的数据应占所有测试样本量的10%。用变换后的测试数据及剩余未变换的数据灌入封闭沙箱，计算得到临床性能指标结果，分析是否有统计学差异。

6.2.2.2 泛化性测试

基于临床性能测试，根据不同维度的数据属性来统计测试结果，从而分别计算不同属性下的临床性能指标，分析是否有统计学差异。例如统计维度为不同地区，则每一类数据属性为中部地区、北部地区、南部地区等。具体统计维度可包括不同地区、不同采集设备厂商等。

Commented [滕依杉 10R10]: 已修改
Commented [9]: 所有图都需要在正文引用，全文修改

6.2.2.3 可再现性/可重复性测试

适用于系统在软件更新或算法更新时。基于上次临床性能测试使用的相同数据集进行第二次测试，所得到的临床性能指标应不劣于上次测试结果。

注：考虑到数据库动态更新等问题，要求测试数据集中有至少50%与首次测试完全相同的数据即可。

6.3 测试后封样

为保证测试环境的封闭性、测试系统与测试数据的安全性以及测试的可复现性，在全部指标测试结束后，需要进行一步测试后封样，测试后封样示意图如图6所示。




图6 测试后封样示意图

步骤如下：

- (1) 测试结束后，输出测试结果；
- (2) 对本次测试进行留档封样，留档数据包括：
 - 一本次测试数据集全部的元数据（包括数据ID、数据属性、数据来源库等）保证测试的可追溯性与可复现性；
 - 一本次测试的元属性（包括本次测试的应用场景、测试策略等）；
 - 一本次测试的测试结果（包括本次测试计算得到的性能指标）；
- (3) 留档封样后，将本次测试的系统与数据一同销毁，保证测试安全性。

参 考 文 献

- [1] 乳腺癌诊疗指南（2022 年版）[J]. 中国合理用药探索, 2022, 19(10):1-26.
- [2] 宫颈癌诊疗规范(2018 年版)[J]. 肿瘤综合治疗电子杂志, 2020, 6(03):33-43.
- [3] 肿瘤病理诊断规范(结直肠癌)[J]. 中华病理学杂志, 2016, 45(12):822-824.
- [4] 周志华. 机器学习[M]. 清华大学出版社, 2006.
- [5] 闫岩琳, 张建. 对诊断一致性 kappa 系数及评价指标的探讨[J]. 中国卫生统计, 2007, 024(003):313-315.
- [6] 周晓华等. 诊断医学中的统计学方法: 第二版[M]. 高等教育出版社, 2016.
- [7] 深度学习辅助决策医疗器械软件审评要点
- [8] GB/T 3358.1-2009 统计学词汇及符号 第1部分: 一般统计术语与用于概率的术语
- [9] ISO/IEC TR 24029-1-2021 人工智能(AI)神经网络鲁棒性的评定第1部分:概述

附录 A

(资料性)

ROC曲线绘制过程

给定 m^+ 个阳性和 m^- 个阴性，根据分类器预测结果对样例进行排序，然后把分类阈值设为最大，即把所有样例均预测为阴性，此时敏感度和1-特异度均为0，在坐标(0,0)处标记一个点，然后将分类阈值依次设为每个样例的预测值，即依次将每个样例划分为阳性，设前一个标记点坐标为 (x,y) ，当前若为真阳性，则对应标记点的坐标为 $(x, y + \frac{1}{m^+})$ ；当前若为假阳性，则对应标记点的坐标为 $(x + \frac{1}{m^-}, y)$ ，然后用线段连接相邻点即得。
