

中华人民共和国通信行业标准

YD/T XXXXX—XXXX

面向互联网的医疗人工智能辅助决策
基于妇科微生态的辅助决策系统算法指标
和测试方法

Algorithm performance index and test method of internet assisted decision—Making product for reproductive
tract infections based vaginal microecology

（报批稿）

XXXX - XX - XX 发布

XXXX - XX - XX 实施

目 次

前 言.....III

1 范围.....1

2 规范性引用文件.....1

3 缩略语.....1

4 术语和定义.....1

5 性能指标及计算方法.....3

 5.1 诊断性能指标.....3

 5.2 其他性能指标.....4

6 测试方法.....4

 6.1 数据集准备.....5

 6.2 测试流程.....5

附录 A（资料性）妇科微生态相关医学名词解释.....8

参考文献.....10

前 言

本文件按照GB/T 1.1—2020《标准化工作导则 第1部分：标准化文件的结构和起草规则》给出的规则起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别专利的责任。

本文件由中国通信标准化协会提出并归口。

本文件起草单位：中国信息通信研究院、苏州图灵微生物科技有限公司、上海商汤智能科技有限公司、北京清华长庚医院、中国医学科学院北京协和医院、北京大学第三医院、腾讯医疗健康（深圳）有限公司、中国移动通信集团有限公司、海纳医信（北京）软件科技有限责任公司、深圳信息通信研究院、郑州信大捷安信息技术股份有限公司、北京邮电大学、中讯邮电咨询设计院有限公司。

本文件主要起草人：郭佳颖、任海英、李曼、闵栋、王进嘉、武玮、徐书宽、梁冰冰、张昊、汪汝亮、刘梦尧、陈敏达、廖秦平、张蕾、朱兰、杨华、李蓉、宋方方、蒋慧、李佳祯、钱天翼、伍建荣、刘金鑫、罗菁、周永新、刘为华、王光宇、刘芳、李野、单丽雅。

面向互联网的医疗人工智能辅助决策

基于妇科微生态的辅助决策系统算法指标和测试方法

1 范围

本文件规定了基于人工智能算法的妇科微生态辅助决策系统的算法指标和测试方法。

本文件适用于采用深度学习、图像处理和模式识别等技术，对妇科镜检图像进行形态学检测，给出相应的诊断结果，辅助医生对妇科微生态情况进行诊断的软件。

2 规范性引用文件

本文件无规范性引用文件。

3 术语和定义

下列术语和定义适用于本文件。

3.1 统计学指标

3.1.1 样本 sample

一个或多个抽样单元组成的总体的子集

3.1.2 置信区间 confidence interval

置信区间是指由样本统计量所构造的总体参数的估计区间

3.1.3 标准正态分布 standardized normal distribution

具有如下概率密度函数的分布：

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, (-\infty < x < +\infty)$$

3.2 人工智能

3.2.1 二分类 binary classification

将对象归入两种类别之一的判断任务或功能。

3.2.2 多分类 multiple classification

将对象归入多种类别之一的判断任务或功能。

3.2.3 准确度 accuracy

被正确分类的样本比例。

3.2.4 敏感度 sensitivity

又称真阳率和召回率，是指实际为阳性的样本中，判断为阳性的比例。

3.2.5 特异度 specificity

又称真阴率，是指实际为阴性的样本中，判断为阴性的比例。

3.2.6 精确度 precision

是指在所有判断为阳性的结果中，真正阳性所占的比例。

3.2.7 F 分数 F-score

F分数是一种统计量，又称为F-measure，是信息检索领域常用的一个评价标准，常用于评价分类模型的好坏。

3.2.8 约登指数 youden's index

也称正确指数，用于评价筛查试验真实性的综合指标，在假阳性与假阴性同等重要时采用，指数越大表示结果真实性越可靠。

3.2.9 Kappa 系数 Kappa coefficient

Kappa系数是一个用于一致性检验的指标，在人工智能领域用来衡量分类精度，可以基于混淆矩阵计算得到。

3.2.10 鲁棒性 robustness

鲁棒性又称健壮性，它是在异常和危险情况下系统生存的关键，是指系统在一定(结构、大小)的参数扰动下维持某些性能的特性。

3.2.11 泛化性 generalization

泛化性是指算法对训练集之外的样本类别的预测能力。算法训练的目的在于学到隐含在数据背后的规律，对具有同一规律的训练集以外的数据，经过训练的算法也能给出合适的输出，即认为该算法泛化性能良好。

3.2.12 可再现性\可重复性 repeatability

在算法测试环境和初始条件相同的情况下，算法对于相同或相似的数据集的不同测试结果之间的一致性即为算法的可再现性/可重复性。该性能指标的评估场景为软件更新或算法更新后的性能测试。

4 缩略语

下列缩略语适用于本文件。

AV	需氧菌性阴道炎	Aerobic Vaginitis
BV	细菌性阴道病	Bacterial Vaginosis
HPF	高倍视野	High Power Field

LBG	乳杆菌分级	Lactobacillus Grades
MV	混合型阴道炎	Mixed Vaginitis
PBC	基底旁上皮细胞	Parabasal Epitheliocytes
TV	滴虫性阴道炎	Trichomoniasis Vaginitis
VVC	外阴阴道假丝酵母菌病	Vulvovaginal Candidiasis

5 性能指标及计算方法

5.1 诊断性能指标

5.1.1 二分类问题转化

为了更好的评价多分类系统在各级分类中的性能表现，将待测系统的多分类问题转化成多个二分类问题，转化方式如下图1所示。其中，数据标签分类中各类妇科微生态感染的定义详见附录A.1—A.4。



图1 多分类问题转化成多个二分类问题示意图

针对每个二分类的分类性能评估指标说明和计算方式如下。

5.1.2 二分类性能指标

5.1.2.1 混淆矩阵

混淆矩阵也称误差矩阵，是用于分类精度评价的一种标准格式，用 n 行 n 列的矩阵形式来表示。以二分类为例，其混淆矩阵如下所示：

表1 混淆矩阵示意表

混淆矩阵		预测值	
		阳性	阴性
真实值	阳性	真阳性	假阴性
	阴性	假阳性	真阴性

其中的几个概念如下：

- 真阳性（True Positive, TP）：样本的真实类别是阳性，且模型预测的结果也是阳性；
- 真阴性（True Negative, TN）：样本的真实类别是阴性，且模型将其预测成为阴性；
- 假阳性（False Positive, FP）：样本的真实类别是阴性，但是模型将其预测成为阳性；
- 假阴性（False Negative, FN）：样本的真实类别是阳性，但是模型将其预测成为阴性。

5.1.2.2 准确度

$$\text{计算公式: } \frac{TP + TN}{TP + TN + FP + FN} \times 100\% \quad (1)$$

5.1.2.3 敏感度

$$\text{计算公式: } \frac{TP}{TP + FN} \times 100\% \quad (2)$$

5.1.2.4 特异度

$$\text{计算公式: } \frac{TN}{TN + FP} \times 100\% \quad (3)$$

5.1.2.5 精确度

$$\text{计算公式: } \frac{TP}{TP + FP} \times 100\% \quad (4)$$

5.1.2.6 F-score

$$\text{计算公式: } (1 + \beta^2) \times \frac{\text{精确度} \times \text{敏感度}}{(\beta^2 \times \text{精确度}) + \text{敏感度}} \quad (5)$$

其中 β 为平衡系数，一般情况下取值为1。

5.1.2.7 约登指数

$$\text{计算公式: } \text{敏感度} + \text{特异度} - 1 \quad (6)$$

5.1.3 多分类性能指标

为了综合评估多分类系统的性能，对各级计算得到的准确度、敏感度、特异度、精确度、F-score、约登指数分别进行加权平均（权重为各级样本数量），得到整个多分类系统的综合指标。

同时，Kappa系数作为衡量分类精度的指标可以比较好地反映多分类系统的综合性能，指标说明和计算公式如下：

说明：Kappa系数是基于混淆矩阵进行计算得到的，Kappa系数的范围为[-1,1]，可以认为Kappa系数越接近1，分类精度越高；Kappa系数越接近-1，分类精度越低。

$$\text{计算公式: } k = \frac{P_0 - P_e}{1 - P_e} \quad (7)$$

其中 P_0 是每一类正确分类的样本数量之和除以总样本数。

假设每一类的真实样本个数分别为 $a_1, a_2, \dots, a_C$ ，而预测出来的每一类的样本个数分别为 $b_1, b_2, \dots, b_C$ ，总样本个数为 n ，则有：

$$P_e = \frac{a_1 \times b_1 + a_2 \times b_2 + \dots + a_C \times b_C}{n^2} \quad (8)$$

5.2 其他性能指标

其他性能指标包括鲁棒性、泛化性、可再现性、可重复性。

6 测试方法

6.1 数据集准备

6.1.1 测试数据集样本抽取

单次测试数据从第三方权威数据库中根据测试样本量要求在每个数据多样化维度（包括医院、患者信息等）进行随机抽取，抽取的测试数据包含妇科下生殖道分泌物微生态形态学镜检图像和数据标签（即金标准，详见附录A.6）。所抽取的测试数据应具有充分的多样性代表，测试数据集中应包含一定比例混合型感染镜检图像和质量不佳的镜检图像。其中，混合型阴道炎定义详见附录A.5，镜检图像产生方式详见附录A.7。

注1：第三方权威数据库指符合《深度学习辅助决策医疗器械软件审评要点》中关于“用于第三方软件确认测试的第三方数据库”专用要求的测评数据库。

注2：对于质量不佳的镜检图像，测试产品应拒绝判断或给出相关字样说明，例如：“无法判断”、“图像不可用”等。

6.1.2 确定测试数据集样本量

测试数据集样本量根据产品预期的特异度和敏感度来确定，可以依照如下计算公式：
根据敏感度指标计算样本量公式：

$$n_1 = \frac{\frac{Z_{\alpha}^2 Psen(1 - Psen)}{2}}{d^2} \quad (9)$$

根据特异度指标计算样本量公式：

$$n_2 = \frac{\frac{Z_{\alpha}^2 Pspe(1 - Pspe)}{2}}{d^2} \quad (10)$$

其中， $Z_{\frac{\alpha}{2}}$ 为 $\frac{\alpha}{2}$ 对应的标准正态分布的上分位数， $Psen$ 为产品提供的预期敏感度， $Pspe$ 为产品提供的预期特异度， d 为置信区间宽度的一半。

二者之和是单次测试样本量的最低要求。测试样本量应在上述统计学计算方式的基础上，以国内同类产品临床实验室病例数据为基准，综合确定。

6.1.3 确定测试数据集样本分布

样本分布应根据待测产品支持辅助诊断的感染类型进行确定。要求测试数据集中包含测一定比例混合型感染镜检图像和质量不佳的镜检图像。同时要求测试数据集应有不同属性，如不同来源地区、不同患者年龄段等，各个属性在测试数据中的分布情况应与实际临床数据相符。

6.2 测试流程

6.2.1 测试前准备

在开始两部分测试前，先进行测试前准备，测试前准备示意图如下图所示：




图2 测试前准备示意图

步骤如下：

- a) 提交检测任务；
- b) 抽取测试数据、提交检测产品；
- c) 灌入封闭安全的测试环境中。在正式开始测试前，计算该待测产品软件包的摘要值，应与产品声称软件包的摘要值保持一致，确保被测试产品的唯一性。

6.2.2 诊断性能测试

诊断性能测试示意图如下图所示：




图3 诊断性能测试示意图

步骤如下：

- a) 在封闭安全的测试环境中开始测试；
- b) 根据预测数据标签、预测概率和原始数据标签计算混淆矩阵；
- c) 根据混淆矩阵计算产品诊断性能指标。

注：产品应声明其面对质量不佳数据无法给出诊断结果时采取的处理方式。

6.2.3 其他性能测试

6.2.3.1 鲁棒性测试

应抽取部分测试数据进行随机的基本变换，来进行产品鲁棒性的测试。其中基本变换包括原图边长5%的裁剪、左右翻转、上下翻转、增加对比度（5%）、减少对比度（5%）、增加亮度（5%）、减少亮度（5%）、增加一定信号幅度的高斯白噪声（5%）。实际测试过程

中应至少包括其中3种变换，具体采取何种变换由产品声称选择。其中进行基本变换的数据应占有所有测试样本量的10%。用变换后的测试数据及剩余未变换的数据灌入封闭沙箱，计算得到诊断性能指标结果，分析是否有统计学差异。

6.2.3.2 泛化性测试

基于诊断性能测试，根据不同维度的数据属性来统计测试结果，从而分别计算不同属性下的诊断性能指标，分析是否有统计学差异。例如统计维度为不同地区，则每一类数据属性为中部地区、北部地区、南部地区等。具体统计维度可包括不同地区、不同患者年龄段等。

6.2.3.3 可再现性/可重复性测试

适用于产品在软件更新或算法更新时。基于上次诊断性能测试使用的相同数据集进行第二次测试，所得到的诊断性能指标应不劣于上次测试结果。

注：考虑到数据库动态更新等问题，要求测试数据集中有至少50%与首次测试完全相同的数据即可。

6.2.4 测试后封样

为保证测试环境的封闭性、测试产品与测试数据的安全性以及测试的可复现性，在全部指标测试结束后，需要进行测试后封样，测试后封样示意图如下图所示。




图4 测试后封样示意图

步骤如下：

- a) 测试结束后，输出测试结果；
- b) 对本次测试进行留档封样，留档数据包括：
 - 1) 本次测试数据集全部的元数据（包括数据 ID、数据属性、数据来源库等）保证测试的可追溯性与可复现性；
 - 2) 本次测试的元属性（包括本次测试的应用场景、测试策略等）；
 - 3) 本次测试的测试结果（包括本次测试计算得到的性能指标）；
- c) 留档封样后，对本次测试的产品与数据一同销毁，保证测试安全性。

附 录 A

(资料性)

妇科微生态相关医学名词解释

A.1 需氧菌性阴道炎 Aerobic Vaginitis

由需氧菌繁殖伴产过氧化氢的乳杆菌减少或缺失导致的炎症。常见的病原菌包括B族链球菌、葡萄球菌、大肠埃希菌及肠球菌等需氧菌。诊断依据见附录A.8。

A.2 细菌性阴道病 Bacterial Vaginosis

由正常产生过氧化氢的乳杆菌减少或缺失而兼性厌氧菌及厌氧菌增多为主导的感染。常见的病原体包括兼性厌氧菌（阴道加德纳菌）、厌氧菌（普雷沃菌、动弯杆菌、拟杆菌、阴道阿托普菌）以及解脲脲原体、人型支原体等。诊断依据见附录A.9。

A.3 滴虫性阴道炎 Trichomoniasis Vaginitis

由毛滴虫感染导致的炎症。显微镜镜检分泌物，革兰染色阳性，发现滴虫，较白细胞略大，形态不规则，内有食物泡，周边有大量的白细胞或上皮细胞碎片。

A.4 外阴阴道假丝酵母菌病 Vulvovaginal Candidiasis

由假丝酵母感染引起的真菌感染性疾病。显微镜镜检分泌物，革兰染色阳性，发现真菌卵圆形孢子、芽生孢子或管状的假菌丝。

A.5 混合型阴道炎 Mixed Vaginitis

由两种及以上的致病微生物导致的炎症。同时存在至少两种病原体或同时满足两种及以上炎症的诊断标准。

A.6 金标准 Gold Standard

金标准是指当前临床医学界公认的诊断疾病的最可靠方法。AV/BV/TV/VVC及混合感染等金标准由临床医师依据数据标注标准对涂片样本进行标注得到。

A.7 妇科微生态形态学镜检图像 Microscopic images of gynecological microecological morphology

第三方权威数据库中妇科微生态形态学镜检图像产生方式如下：

- 临床医生采用阴道分泌物专用热塑性聚氨酯弹性体（TPU）材质一次性采样拭子进行采样，保证样本充分获得和释放，并保证细胞不被破坏和取样量的一致。取样后将拭子置于液基细胞和微生物检测处理、保存试剂（阴道微生态形态学专用）样本管中充分释放，保证有形成分均匀分散；
- 使用液基薄层细胞制片原理的自动样本制片机对阴道分泌物样本进行制片，保证样本在玻片有效区域内均匀分布；
- 使用自动化革兰染色机对制好的玻片样本进行革兰染色（染色前设备需要通过质控）；
- 使用显微图像扫描仪对玻片进行显微成像，显微镜物镜和相机参数因保证单个图片对应视野尺寸与100倍油镜和10倍目镜下视野大小一致，符合形态学诊断规定；

- e) 数据库中图像均经过第三方临床具有权威性的资深检验或病理医师进行数据标签标注，包括数据质量合格性、AV评分、Nugent评分、VVC结果（菌丝、芽生孢子、孢子）、TV结果。

A.8 革兰染色涂片结合临床特征的 AV 联合诊断标准 AV Diagnostic Criteria

基于革兰染色涂片AV的诊断标准，可实现同一张涂片上同时诊断AV、BV、VVC、TV共4种常见阴道炎及其混合感染，提高诊断效率，具有良好的实用性及可推广性。AV联合诊断标准共5项指标，包括：白细胞数、PBC所占比例、LBG、背景菌落和临床特征（阴道pH值、阴道黏膜充血和黄色分泌物）。每项指标0-2分，总分10分， ≥ 4 分时诊断为AV。由于测试数据集可能未包含临床特征，因此仅考虑可从图像中获得的指标进行AV诊断，每项指标0-2分，总分8分， ≥ 3 分时诊断为AV。具体见表A.1。

表A.1 革兰染色涂片结合临床特征的AV联合诊断标准

AV评分	LBG ¹	背景菌落	白细胞数 ²	PBC所占比例 ³	临床特征
0	I 或 II a 级	无明显杂菌	≤ 10 个/HPF	$< 1\%$	pH值 ≤ 4.5 且无异常体征 ⁴
1	II b级	肠杆菌样小杆菌	> 10 个/HPF且 ≤ 10 个/上皮细胞	$\geq 1\%$ 且 $\leq 10\%$	pH值 > 4.5 或出现任意1项或2项异常体征
2	III级	球菌样或呈链状	> 10 个/上皮细胞	$> 10\%$	pH值 > 4.5 且出现任意1项或2项异常体征

注：1.LBG：1000x下评估。I级：指多量多形性乳杆菌，无其他细菌；II a级：指混合菌群，但主要为乳杆菌；II b级：指混合菌群，但乳杆菌比例明显减少，少于其他菌群；III级：乳杆菌严重减少或缺失，其他细菌过度增长。2.400x下评估。3.PBC：基底旁上皮细胞比例，400x下评估。4.异常体征：阴道黏膜充血、黄色分泌物。

A.9 Nugent 评分 Nugent Score

细菌性阴道病的诊断依据之一，是目前国际通用的一种诊断方法。评分方法为将阴道分泌物进行革兰染色，在显微镜（1000倍油镜）下观察不同细菌的形态类型，并进行量化和综合评分，总分范围为0-10分；评分 ≥ 7 分诊断为BV。具体见表A.2。

表A.2 Nugent评分标准

评分	乳杆菌	阴道加德纳菌及类杆菌	染色不定的弯曲杆菌
0	4+	0	-
1	3+	1+	1+或2+
2	2+	2+	3+或4+
3	1+	3+	-
4	0	4+	-

注：0：油镜视野未见细菌；1+： < 1 个细菌/油镜视野（此为平均数）；2+：1~4个细菌/油镜视野；3+：5~30个细菌/油镜视野；4+： > 30 个细菌/油镜视野；一无此项。

参考文献

- [1] 中华医学会妇产科学分会感染性疾病协作组. 阴道微生态评价的临床应用专家共识[J]. 中华妇产科杂志, 2016, 51(010):721-723.
 - [2] 董梦婷, 王辰, 李会阳, 等. 基于革兰染色涂片结合临床特征的需氧菌性阴道炎联合诊断标准专家建议[J]. 中国实用妇科与产科杂志, 2021, 37(3): 327-335.
 - [3] 中华医学会妇产科学分会感染性疾病协作组. 细菌性阴道病诊治指南(2021 修订版)[J]. 中华妇产科杂志, 2021, 56(1):4.
 - [4] 中华医学会妇产科学分会感染性疾病协作组. 阴道毛滴虫病诊治指南(2021 修订版)[J]. 中华妇产科杂志, 2021, 56(1):4.
 - [5] 李萌, 张琼琼, 廖秦平. 美国 CDC《2021 年性传播感染诊治指南》外阴阴道假丝酵母菌病诊治解读[J]. 中国微生态学杂志, 2021(011):033.
-